



OTIMIZAÇÃO DE PORTFÓLIOS DE COMERCIALIZAÇÃO DE ENERGIA NO BRASIL

Mário Guerreiro Ribeiro

Dissertação de Mestrado apresentada à
Escola de Pós-Graduação em Economia da
Fundação Getúlio Vargas como parte dos
requisitos necessários para a obtenção do
grau de mestre.

Área de Concentração: Finanças / Economia

Orientadores: Edson Daniel Lopes Gonçalves
João Carlos de Oliveira Mello

Rio de Janeiro
Maio de 2017

Ribeiro, Mário Guerreiro

Otimização de portfólios de comercialização de energia no
Brasil / Mário Guerreiro Ribeiro. – 2017.
71 f.

Dissertação (mestrado) - Fundação Getulio Vargas, Escola de Pós-
Graduação em Economia.

Orientador: Edson Daniel Lopes Gonçalves.

Coorientador: Joao Carlos de Oliveira Mello.

Inclui bibliografia.

1. Investimentos. 2. Risco (Economia). 3. Energia - Brasil.

I. Gonçalves, Edson Daniel Lopes. II. Mello, João Carlos de Oliveira.

III. Fundação Getulio Vargas. Escola de Pós-Graduação em
Economia. IV. Título.

CDD – 332.6




MÁRIO GUERREIRO RIBEIRO


**“OTIMIZAÇÃO DE PORTFÓLIOS DE COMERCIALIZAÇÃO DE
ENERGIA NO BRASIL”**


Dissertação apresentada ao Curso de Mestrado Profissional em Economia Empresarial e Finanças da Escola de Pós-Graduação em Economia para obtenção do grau de Mestre em Economia Empresarial e Finanças.

Data da defesa: 22/05/2017

ASSINATURA DOS MEMBROS DA BANCA EXAMINADORA


Edson Daniel Lopes Gonçalves
Orientador (a)


Gustavo Ayala


João Carlos de Oliveira Mello

*Dedico esta dissertação aos meus
pais Hédio e Regina Guerreiro*

Agradecimentos

Agradeço primeiramente aos meus pais Hélio e Regina Guerreiro por terem me apoiado em todas as minhas decisões, por terem formado meu caráter e pela dedicação de ambos.

Ao Dr. Carlos Ivan Simonsen Leal, por ser muito mais que um orientador, um padrinho que eu ganhei tardiamente. Agradeço imensamente por você ter me mostrado caminhos antes desconhecidos e por fazer nascer dentro de mim a paixão pelo estudos da economia. Obrigado pelo tempo despendido em nossas reuniões semanais, pela paciência, pelos conselhos e por todos os ensinamentos acadêmicos e de vida. Você me transformou e fez com que eu perseguisse sempre a excelência.

Ao meu irmão Hélio Guerreiro por todo seu carinho.

À minha esposa Priscilla por estar sempre ao meu lado.

A todos os professores do MFEE e da EPGE.

À Fundação Getúlio Vargas.

Ao meu orientador Dr. Edson Daniel Lopes Gonçalves por ter me ajudado no desenvolvimento desta dissertação.

Ao meu co-orientador Dr. João Carlos de Oliveira Mello por toda a ajuda, presteza e paciência.

Ao amigo Frederico Botelho por toda a sua ajuda com as modelagens do NEWAVE.

Ao amigo Nicolás Netto que sempre esteve disponível para me ajudar com a edição em LaTeX desta dissertação.

À Argucia Capital Management, principalmente ao Ricardo Magalhães, por todo incentivo e ajuda.

Resumo da Dissertação apresentada à EPGE/FGV como parte dos requisitos necessários para a obtenção do grau de mestre

OTIMIZAÇÃO DE PORTFÓLIOS DE COMERCIALIZAÇÃO DE ENERGIA NO BRASIL

Mário Guerreiro Ribeiro

Maio/2017

Orientadores: Edson Daniel Lopes Gonçalves

João Carlos de Oliveira Mello

Área de Concentração: Finanças / Economia

A análise da otimização de carteiras por muito tempo foi pautada na medida da variância. Essa abordagem é propícia quando os retornos dos ativos são normais. Porém, em distribuições assimétricas ou com caudas pesadas não se pode dar o mesmo peso para as duas extremidades da distribuição, levando a necessidade da utilização de outras medidas de risco. Uma das mais conhecidas e difundidas é o VaR, porém o mesmo não consegue capturar eventos extremos, além de não ser uma medida coerente e possuir problemas de otimização. Por esses motivos, o CVaR é abordado para o caso da otimização de portfólios do setor de energia elétrica brasileiro.

Abstract of Dissertation presented to EPGE/FGVE as a partial fulfillment of the requirements for the degree of master

POWER PORTFOLIO OPTIMIZATION IN BRAZIL

Mário Guerreiro Ribeiro

May/2017

Advisors: Edson Daniel Lopes Gonçalves
João Carlos de Oliveira Mello

Department: Finance / Economy

The portfolio optimization analysis for quite some time was built around the variance measure. This approach is adequate when the assets returns are normally distributed. However, in asymmetric or heavy-tailed distributions, the same weight cannot be given to the two tails of the distribution, what requires the use of other risk measures. One of the most known and widespread is VaR, but it cannot capture extreme events, is not a coherent measure and has optimization problems. For these reasons, the dissertation addresses the CVaR on the portfolio optimization for the Brazilian electric power sector.

Sumário

Lista de Figuras	xii
Lista de Tabelas	xiii
1 Introdução	1
1.1 Objetivo	1
1.2 Organização da Tese	2
2 Mercado de Energia Elétrica no Brasil	3
2.1 Geração de Energia Elétrica no Brasil	3
2.1.1 O Sistema Interligado Nacional	6
2.2 Comercialização de Energia Elétrica	8
2.2.1 As Duas Regras Básicas para a Segurança da Oferta	8
2.2.2 Garantia Física	9
2.2.3 Contratos de Energia no Brasil	10
2.2.4 Mecanismo de Realocação de Energia: MRE	12
2.3 Os Ambientes de Contratação	13
2.4 Modelos do ONS e a Formação do PLD na CCEE	15
2.5 Testes com o PLD	20
2.5.1 Teste da Distribuição dos Retornos	21
2.5.2 Estudo de Caso: Reversão à Média da Simulação pelo NEWAVE	23
2.5.3 Movimento Browniano Geométrico e Teste de Reversão à Média	25
2.5.4 Teste de Raiz Unitária	26
2.5.5 Modelagem final do PLD	27
3 Risco	29
3.1 Desvio Padrão	30
3.2 VaR	31
3.3 CVaR	32
3.3.1 Exemplo de Comparação entre VaR e CVaR	34

3.4	Otimização do CVaR	37
4	Otimização de Carteiras	39
4.0.1	Ativos da Carteira Considerada	40
4.1	Estudo de Caso	41
4.2	Resultados da otimização	44
4.2.1	Teste de Normalidade	49
4.2.2	Otimização com IC de 99%	49
5	Conclusões	50
6	Trabalhos Futuros	51
	Referências Bibliográficas	52
A	Códigos Implementados	54

Lista de Figuras

2.1	<i>Capacidade Instalada do Sistema Brasileiro</i>	4
2.2	<i>Quociente da EARMÁX e a Capacidade Insatalada das Usinas Hidrelétricas, Fonte: FALCETTA</i>	6
2.3	<i>Sazonalização e Modulação da Garantia Física Anual. Fonte:CCEE (2010)</i>	11
2.4	<i>Processo de Decisão para Sistemas Hidrotérmicos</i>	16
2.5	<i>Custo de Oportunidade e Cálculo do CMO</i>	17
2.6	<i>Funções de Custo Futuro (FCF) e Imediato (FCI) x Armazenamento</i>	18
2.7	<i>Cadeia de Modelos Computacionais</i>	18
2.8	<i>Modelo NEWAVE - Inputs e Outputs</i>	19
2.9	<i>Histórico do PLD no subsistema SE/CO</i>	21
2.10	<i>Histograma dos Retornos Históricos do PLD</i>	22
2.11	<i>Histograma com Normal Teórica dos Retornos Históricos do PLD</i>	22
2.12	<i>Rodada NEWAVE com Três Cenários</i>	24
2.13	<i>Correlograma: Série PLD SE/CO</i>	27
3.1	<i>Histograma da Simulação de Retornos Normais</i>	35
3.2	<i>Histograma da Simulação de Retornos com Cauda Esquerda Pesada</i>	36
4.1	<i>Média das Séries do NEWAVE</i>	43
4.2	<i>Fronteira Eficiente CVaR</i>	44
4.3	<i>Fronteira Eficiente Média Variância</i>	45
4.4	<i>Fronteiras Eficientes: $E[R] \times CVaR$</i>	46
4.5	<i>Fronteiras Eficientes: $E[R] \times \sigma$</i>	46
4.6	<i>Histograma Retornos</i>	47
4.7	<i>Alocação dos Ativos nos Portfólios Ótimos</i>	48
4.8	<i>Fronteiras Eficientes CVaR - $\alpha = 95\%$ e $\alpha = 99\%$</i>	49

Lista de Tabelas

2.1	Capacidade de Armazenamento dos Submercados	7
2.2	MLTs (MWmed) por Subsistemas a partir de 27/08/2016	7
2.3	Matriz de Correlações das MLTs dos Submercados	8
2.4	<i>Teste Dickey-Fuller Aumentado: Série PLD SE/CO</i>	26
3.1	VaR e CVaR para uma simulação Genérica de Retornos com Nível de Significância de 10%	36
3.2	VaR e CVaR para uma simulação Genérica de Retornos com Nível de Significância de 5%	36
3.3	VaR e CVaR para uma simulação Genérica de Retornos com Nível de Significância de 1%	37
3.4	Erro Percentual do Cálculo do VaR Aproximado para o Nível de Significância de 5%	37

Capítulo 1

Introdução

A escolha de um portfólio ótimo em que o risco é minimizado para um determinado retorno é um dos temas centrais de finanças e economia. O *trade-off* entre risco e retorno é talvez a variável decisória mais importante para um gestor de carteira de investimentos.

Em 1952, Markowitz, em seu célebre artigo “Portfolio selection: efficient diversification of investments” introduziu a ideia da importância da diversificação e uma maneira de se avaliar um retorno ótimo condicionado a um risco mínimo. Este risco era então definido pela medida de variância de um ativo financeiro. Esta abordagem de otimização ficou conhecida como “Otimização de Média Variância”.

Para ativos com retornos com distribuições normais, a otimização de média variância trata bem o problema proposto. Porém, para o caso em que os portfólios a serem analisados não possuem distribuições normais, esta abordagem falha por conferir o mesmo peso às duas caudas da distribuição. Assim, esta metodologia não trata de maneira adequada o problema proposto.

O CVaR, do inglês *Conditional Value at Risk*, é capaz de tratar o problema da otimização de maneira efetiva nos casos em que a distribuição do portfólio é normal e nos casos em que a normalidade não se verifica. Além disto, uma característica interessante da utilização da otimização que minimiza o CVaR é que a mesma confere resultados iguais aos da abordagem para carteiras otimizadas por média variância. Em casos em que a distribuição do portfólio não é normal, com caudas pesadas, o CVaR é capaz de introduzir esta característica estatística ao problema de otimização.

1.1 Objetivo

Em muitos casos no campo das finanças, a hipótese de normalidade para retornos é refutada. O mercado brasileiro de energia elétrica é um dos mercados que apresenta esta

característica para o preço spot. Por este motivo, o presente trabalho busca contextualizar a otimização com minimização do CVaR aplicada ao mercado de comercialização de energia elétrica brasileiro e suas particularidades.

1.2 Organização da Tese

A dissertação busca discorrer sobre a otimização com minimização do CVaR para o mercado de comercialização de energia elétrica brasileiro. A dissertação começa com a caracterização deste mercado, no capítulo 2. No capítulo 3 são abordadas medidas de risco: Desvio padrão, VaR e CVaR, além de introduzir o escopo teórico das otimizações de média variância e da otimização do CVaR. No capítulo 4 é feito o estudo de caso da otimização de carteira utilizando as abordagens do CVaR e da média variância para o problema da escolha da carteira ótima de um consumidor que precisa fazer sua contratação de energia para um horizonte de 5 anos. A conclusão, no capítulo 5, mostra de forma resumida os resultados obtidos, e o capítulo 6 propõe o desenvolvimento dos mesmos em trabalhos futuros.

Capítulo 2

Mercado de Energia Elétrica no Brasil

Neste capítulo será descrito e analisado o mercado de energia elétrica no Brasil com foco nos seguintes assuntos:

- Geração de energia;
- Consumo;
- Comercialização.

2.1 Geração de Energia Elétrica no Brasil

O Brasil é um país com geração predominantemente hidrotérmica, ou seja, a matriz energética é composta em sua maioria por usinas hidrelétricas e térmicas. O *mix* da capacidade instalada brasileira vem mudando ao longo dos anos, de forma que o percentual da capacidade instalada da geração hidrelétrica vem sendo diluído com a entrada de usinas diversificando o portfólio de geração nacional como: usinas térmicas a carvão e a gás, eólicas, biomassa e solar. A Agência Nacional de Energia Elétrica (ANEEL), autarquia em regime especial vinculada ao Ministério de Minas e Energia, foi criada para regular o setor elétrico brasileiro por meio da Lei no 9.427/1996 e do Decreto no 2.335/1997. Ela é responsável por ANEEL (2016):

- Regular a geração, transmissão, distribuição e comercialização de energia elétrica;
- Fiscalizar, diretamente ou mediante convênios com órgãos estaduais, as concessões, as permissões e os serviços de energia elétrica;
- Implementar as políticas e diretrizes do governo federal relativas à exploração da energia elétrica e ao aproveitamento dos potenciais hidráulicos;

- Estabelecer tarifas;
- Dirimir as divergências, na esfera administrativa, entre os agentes e entre esses agentes e os consumidores, e
- Promover as atividades de outorgas de concessão, permissão e autorização de empreendimentos e serviços de energia elétrica, por delegação do Governo Federal.

O *mix* da capacidade instalada brasileira até 31/12/2015 era composto pela divisão apresentada na figura 2.1 ANEEL (2016).




Figura 2.1: *Capacidade Instalada do Sistema Brasileiro*

As usinas hidrelétricas são divididas em três grupos referentes à capacidade instalada das mesmas enquanto que as usinas térmicas são divididas em dois grupos referentes ao tipo de combustível:

I Usinas hidrelétricas:

Pequena Central Hidrelétrica (PCH): Capacidade Instalada entre 3.000 kW e 30.000 kW e com área de reservatório de até 13 km² Resolução normativa nº 673/2015;

Centrais Geradoras Hidrelétricas (CGH): Capacidade Instalada até 3.000 kW;

UHE: Capacidade Instalada maior que 30.000 kW.

II Usinas Térmicas:

Usina Termelétricas (UTE);

Usina Termonuclear (UTN).

Uma característica interessante e mitigadora de risco de déficit de oferta de energia são os reservatórios das hidrelétricas brasileiras. Eles permitem uma regularização plurianual, ou seja, mesmo em anos marcados por hidrologias ruins, os reservatórios conseguem armazenar água suficiente para que a energia continue sendo gerada. Porém, por questões ambientais, reforçadas pela expansão dessa fonte na região amazônica, novas usinas hidrelétricas com grandes reservatórios estão dando lugar a usinas com reservatórios menores ou usinas a fio d'água, que geram uma instabilidade maior na capacidade de oferta do sistema.

A figura 2.2 mostra a evolução do quociente entre capacidade de armazenamento dos reservatórios (EARMÁX) e a Capacidade Instalada das usinas hidrelétricas do sistema. Observa-se que desde 2010 houve uma perda considerável da capacidade de regularização, fato que gera uma maior volatilidade esperada dos preços de energia uma vez que a probabilidade da necessidade de despacho de outras fontes mais caras para o atendimento à carga torna-se maior.




Figura 2.2: Quociente da EARMAX e a Capacidade Instalada das Usinas Hidrelétricas, Fonte: FALCETTA

2.1.1 O Sistema Interligado Nacional

O Brasil é um país de dimensões continentais com 8,5 quilômetros quadrados de área. Essa é uma característica interessante do ponto de vista da diversidade das diferentes regiões do país do ponto de vista geológico e climático. Porém é um ponto desafiador para a transmissão de energia.

O sistema elétrico brasileiro é dividido em quatro regiões geográficas chamadas de subsistemas: Sudeste Centro-Oeste (SE/CO), Sul (S), Nordeste (NE) e Norte (N). Esses subsistemas são interligados por linhas de transmissão formando o chamado Sistema Interligado Nacional. Apenas 1,7% da demanda do país encontra-se fora do SIN em pequenos sistemas isolados localizados principalmente na região da Amazônia ONS (2016).

Os submercados apresentam diferentes características climáticas e geográficas. Dessa forma o parque de geração de cada submercado tem características específicas a cada submercado. Uma dessas características é a capacidade de armazenamento hídrica proveniente das hidrelétricas atualmente em funcionamento no SIN, apresen-

tada na tabela 2.1.

Tabela 2.1: Capacidade de Armazenamento dos Submercados

Submercado	EARMÁX	%
SE/CO	202.851	70,03
S	19.957	6,89
NE	15.043	5,19
N	51.811	17,89

A geração hidrelétrica é dependente das afluições, ou seja da vazão de água que passa pelas usinas hidrelétricas. O ONS possui um histórico dessas vazões desde 1931 para as principais bacias. De posse desse histórico são calculadas as médias de afluição das bacias dos submercados conhecidas como Médias de Longo Termo (MLTs). Essas médias estão intimamente ligadas com a capacidade hidrelétrica dessas bacias, ou seja, novas entradas de capacidade ou possíveis fechamentos de usinas ocasionam mudanças nas MLTs para refletir esse novo parque de geração.

A tabela 2.2 apresenta as MLTs mensais de cada subsistema em MWmed. É possível observar que os meses de MLT mais altas no SE, NE e N são os meses de MLT mais baixas no S, o que se verifica através da matriz de correlações 2.3. Essa característica do sistema brasileiro corrobora com a existência do SIN e da interligação de diversas áreas e dos subsistemas do Brasil através de linhas de transmissão. Em períodos mais secos no Sul, os demais subsistemas podem exportar energia para esse submercado, enquanto nos períodos de maior afluição no Sul, esse torna-se exportador.

Tabela 2.2: MLTs (MWmed) por Subsistemas a partir de 27/08/2016

	SE	S	NE	N
Janeiro	64.455	7.305	14.121	10.212
Fevereiro	69.231	8.309	14.764	13.797
Março	67.018	7.048	14.700	16.192
Abril	53.170	6.602	11.993	16.221
Maio	38.668	8.598	7.265	11.144
Junho	31.630	10.293	4.793	5.982
Julho	25.096	10.977	3.954	3.707
Agosto	20.165	10.281	3.445	2.586
Setembro	19.423	12.006	3.082	1.950
Outubro	23.347	13.318	3.371	2.016
Novembro	30.605	9.344	5.516	3.122
Dezembro	46.905	7.386	10.167	5.916

Tabela 2.3: Matriz de Correlações das MLTs dos Submercados

	SE	S	NE	N
SE	1,00	- 0,83	0,99	0,87
S	- 0,83	1,00	- 0,85	- 0,81
NE	0,99	- 0,85	1,00	0,87
N	0,87	- 0,81	0,87	1,00

2.2 Comercialização de Energia Elétrica

2.2.1 As Duas Regras Básicas para a Segurança da Oferta

A fim de garantir a segurança da oferta de energia, duas regras básicas foram criadas de forma a incentivar a expansão da oferta em conformidade com as expectativas de evolução da demanda DE CASTRO *et al.*.

- **Regra Básica 1:** 100% do consumo das distribuidoras deve estar lastreado em contratos ;
- **Regra Básica 2:** Os consumidores livres precisam lastrear seu consumo em garantia física.

A primeira regra estabelece que todo consumo de energia deve ter de estar atrelado a um contrato de energia tanto para companhias de distribuição quanto para consumidores livres. As distribuidoras são responsáveis por contratar energia para seus consumidores regulados, enquanto os consumidores livres são responsáveis pela suas próprias contratações de energia para que suas demandas sejam plenamente atendidas contratualmente. Um contrato de energia só é válido se a energia for registrada na CCEE. A auto-produção se enquadra na primeira regra, simulando um contrato automático. A grande maioria dos contratos bilaterais no mercado de energia brasileiro são contratos forwards take-or-pay nos quais o vendedor assume o risco de preço e quantidade. A CCEE checa mensalmente se o consumo acumulado de um agente (medido em MWh) nos últimos 12 meses é menor ou igual ao volume contratado pelo mesmo.

A segunda regra estabelece que toda a energia vendida deve ser lastreada por garantia física. A garantia física de cada usina de geração elétrica, independente da fonte, é estabelecida pelo MME e tem relação com a capacidade de produção sustentável de uma usina.

As duas regras básicas incentivam a expansão do sistema, já que qualquer consumo adicional de MWh deve ser acompanhado de um novo contrato de energia lastreado em garantia física. Isso dá conforto para investidores em projetos de *greenfield* diminuindo incertezas em relação à demanda futura para a energia desses projetos.

2.2.2 Garantia Física

A garantia física é definida como a quantidade máxima de energia elétrica que um empreendimento de geração, incluindo importação, que pode ser utilizada para comprovação de atendimento de carga ou comercialização por meios de contratos CCEE (2010). A Lei nº 10.848/04, regulamentada pelo art. 2º do Decreto nº 5.163/04 estabelece a definição da garantia física. As portarias MME nº 303, de 18/03/2004 e nº 258, de 28/07/2008 descrevem a metodologia e diretrizes para a determinação da garantia física das usinas do SIN.

Segundo CCEE (2010), a garantia física do SIN corresponde a quantidade máxima de energia que este sistema pode suprir a um dado critério de garantia de suprimento. Esta energia é rateada entre todos os empreendimentos de geração, divididos em empreendimentos hidráulicos e não-hidráulicos, para a obtenção da garantia física de cada empreendimento com vistas à comercialização de energia via contratos.

A forma do cálculo das garantias físicas varia quanto ao tipo de usina (hidráulica ou não-hidráulica), considera também a participação no Mecanismo de Realocação de Energia, a modalidade de despacho e se o empreendimento possui ou não garantia física estabelecida pelo MME. Para este último caso específico, considera-se a garantia física como sendo a geração medida da usina no período de comercialização CCEE (2010).

O cálculo da garantia física é complexo e como explicado acima, varia de acordo com o tipo da usina. De maneira geral, o certificado de energia assegurada emitido pelo MME para cada gerador hidrelétrico representa a capacidade de produção de energia elétrica sustentável em anos de hidrologia desfavorável. Para geradores termelétricos, o certificado de energia assegurada é calculado com base na disponibilidade da usina, descontada dos tempos de manutenção média e de parada forçada das plantas, ajustada por um fator dependente do custo variável de unitário (CVU ¹). Esse fator de ajuste é explicado pelo fato de quanto mais cara for o despacho de uma usina, essa deve ser despachada apenas depois das demais usinas mais baratas. Uma usina

¹O Custo Variável Unitário (CVU) se refere aos projetos de geração considerados pela EPE para definição da garantia física de empreendimentos de geração não hidráulica, utilizado para a seleção de empreendimentos a serem contratados, na modalidade de disponibilidade de energia. O CVU é função do custo de combustível, expresso em R\$/MWh, custo de operação e manutenção variável, encargos e impostos.

à diesel seria despachada apenas após os despacho de usinas à gás natural. Dessa maneira as usinas com custo de despacho mais baixo tem uma maior contribuição na geração do sistema. No limite, uma usina com custo variável igual ao custo de racionamento deveria ter um certificado de energia assegurada igual a 0 MWmed.

Devido a grande importância das duas regras básicas para o sistema, qualquer desvio à essas regras pode gerar penalidades severas tanto financeiras (multas) quanto regulatórias (um agente pode ser excluído da CCEE por exemplo).

2.2.3 Contratos de Energia no Brasil

Para a garantia do bom funcionamento do mercado e da respeito às duas regras básicas, todos os contratos devem ser registrados na CCEE tanto para o ambiente de contratação livre quanto para o regulado. Alguns contratos permitem algumas particularidades na forma como a energia é registrada. Uma característica presente em contratos é a sazonalidade, permitindo a pré-alocação mensal de energia usado para especular com o preço spot. O limite mínimo e máximo para essa estratégia são iguais a zero e a capacidade instalada total (limite de potência), respectivamente. Uma estratégia empregada na sazonalidade seria a redução do volume contratado no período úmido, quando em geral são esperados preços mais baixos e um aumento do volume contratado no período seco, quando em geral são esperados preços mais alto. O volume total do contrato em MWh deve ser respeitado de forma que a soma dessas diferentes alocações seja igual ao volume total contratado. A revisão da sazonalização ocorre caso a usina em questão sofra alteração na sua garantia física. A sazonalização é por lei escolhida no ano anterior ao ano da vigência da entrega da energia, feita no mês de dezembro. As distribuidoras tem regras mais restritas para o uso da sazonalização CCEE (2015).

Outras duas características podem estar presentes em contratos: flexibilidade e modulação. A flexibilidade é a possibilidade de aumento ou redução do registro da energia mês a mês na CCEE limitado a um percentual de forma que a soma da energia registrada no período do contrato seja igual ao volume total do contrato estabelecido em MWh. A modulação estabelece a alocação intradiária distribuída em valores horários da energia para cobertura de picos de demanda, mantendo a média mensal estabelecida contratualmente. A figura 2.3 apresenta um esquema da sazonalização e modulação da garantia física de uma usina.




Figura 2.3: Sazonalização e Modulação da Garantia Física Anual. Fonte: CCEE (2010)

Termos Típicos nos Contratos

Um Contrato de Compra e Venda de Energia (CCVE) típico é um contrato bilateral em que ambas as partes concordam com termos específicos que dependem de cada transação comercial. Para contratos com mais de 1 ano, além das cláusulas de sazonalização, flexibilidade e modulação, os contratos geralmente também incluem: (i) submercado no qual a energia será entregue; (ii) cláusula sobre racionamento, ditando as possíveis mudanças nos termos do contrato caso ocorra racionamento no período de vigência; (iii) cláusulas de perdas, sendo o ponto de entrega da energia geralmente no centro de gravidade do submercado ²; (iv) outras cláusulas referentes a regulação do setor; (v) forma de pagamento; (vi) indexação (IPCA ou IGP-M) contabilizados geralmente na data de aniversário do contrato; (vii) penalidades contratuais; e, (viii) resolução de disputas, força maior entre outras cláusulas.

O racionamento de energia é um caso específico para o mercado e caso o mesmo ocorra, as distribuidoras e comercializadoras não devem ser responsáveis pela oferta de energia para os consumidores. Um importante aspecto dos CCVEs é que eles são contratos puramente financeiros, lastreados em garantia firme. Caso haja raciona-

²Centro de gravidade é um ponto virtual dentro do submercado onde as perdas são igualmente distribuídas entre os geradores e os consumidores

mento, os consumidores a princípio não seriam cobertos totalmente pelos seus presentes contratos (no caso da demanda ser igual ao volume dos contratos comprados). Não existe regulação formal para o caso do racionamento, apesar do sistema ter passado por um racionamento em 2001. No caso de um racionamento, os volumes contratuais seriam reduzidos na proporção do mesmo, salvo algumas exceções.

2.2.4 Mecanismo de Realocação de Energia: MRE

Contratos bilaterais com preço fixo protegem os geradores do risco de preço representado por PLDs baixos. Existe, porém um *trade-off* já que quando um gerador vende energia a um preço fixo, o mesmo incorre do risco de quantidade por não produzir a energia que deveria, tendo assim que comprar energia no mercado de curto prazo podendo ter grandes perdas financeiras no caso de PLDs altos. O risco de quantidade é muito pequeno para usinas termelétricas. Para essas usinas, a capacidade de produção é sempre maior que a energia vendida, isto é, caso não haja nenhum imprevisto referente ao tempo de manutenção, a indisponibilidade para esse tipo de usina só ocorre no caso de parada forçada ou de falta de combustível, ambos casos *ceteris paribus* com baixa probabilidade de ocorrência.

No Brasil o despacho de usinas é feito de maneira centralizada pelo ONS. Isso significa que as usinas não tem poder de decisão sobre a sua produção, o que gera um grande problema de incentivos para um sistema com usinas hidrelétricas em cascata pertencentes a diferentes acionistas: o ótimo individual não corresponde ao ótimo global. Essa forma de despacho também não leva em consideração as obrigações contratuais individuais das usinas. Como o despacho é centralizado, ou seja, a água é de todos e o seu uso não é decidido pelo proprietário da usina, o MRE minimiza e compartilha entre os perfis de geração dos agentes o risco de venda de energia em Longo Prazo ANEEL (2016).

Dadas as grandes dimensões territoriais do Brasil, existem também diferenças hidrológicas significativas entre as regiões, ou seja, períodos secos e úmidos não coincidentes, fazendo com que existam transferências de energia entre regiões. Uma região em período seco deve armazenar água, produzindo abaixo da média, enquanto uma região úmida produz acima da média.

Essas características do SIN fazem com que o *trade-off* de uma usina estar pouco contratada ou muito contratada seja bastante relevante (se estiver pouco contratada pode ter frustração de receita com PLDs baixos e se estiver muito contratada pode ter custos muito altos caso a produção seja menor que a garantia física e o PLD esteja alto). Para solucionar esse problema, foi criado o Mecanismo de Realocação de Energia (MRE). O MRE é um esquema de *hedging* compulsório que alivia o risco de

produção individual, uma vez que divide esse risco com os outros participantes, funcionando como um condomínio, além disso a produção conjunta é muito mais estável que a produção individual. Este tipo de mecanismo por enquanto só existe para usinas hidrelétricas.

O MRE funciona basicamente da seguinte maneira:

- I A garantia física de todas as usinas participantes do mecanismo é somada e cada participante fica com uma cota correspondente ao percentual que sua garantia física representa no todo (a soma das cotas deve ser igual a 1);
- II Cada planta recebe um crédito horário dado em MWh, função da sua respectiva cota. Assim, cada planta tem um crédito horário desassociado da sua produção física;
- III As cotas devem somar 1, dessa maneira a soma dos créditos fornecidos é igual a produção total dos participantes do MRE. Assim, caso alguma planta produza menos que seu crédito, as outras plantas irão automaticamente compensá-la.

O MRE não é um *hedge* contra um risco sistêmico, i.e. no caso da produção total em um determinado mês dos participantes do MRE ser menor que a garantia física dos mesmos somada, o mecanismo é penalizado ao PLD daquele mês e a penalidade é então rateada. Para os casos de geração total dos participantes maior ou menor que a soma de suas garantias físicas, aparece o conceito de *Generation Scaling Factor* (GSF) que quando é menor que 1 pode gerar altas perdas financeiras. Para maiores detalhes do GSF e da sua gestão do risco vide JAPPE *et al.* (2014).

Como forma de compensar as usinas que produziram mais do que a sua garantia física sazonalizada em determinado mês e penalizar as usinas que produziram menos, criou-se o mecanismo da chamada Tarifa de Energia de Otimização (TEO) para valorar a energia elétrica transferida entre as usinas participantes do MRE. Através da Resolução Homologatória da ANEEL nº 2.002 de dezembro de 2015, a TEO vigente em 2016 foi definida como sendo igual a R\$ 12,32/MWh.

2.3 Os Ambientes de Contratação

Existem dois ambientes de contratação no mercado de energia elétrica brasileiro: o Ambiente de Contratação Regulado (ACR) e o Ambiente de Contratação Livre (ACL). Enquanto o ACL permite a comercialização de energia entre todos os agentes via contratos bilaterais, o ACR é um mercado mais restrito e dependente de leilões. O Decreto 4.562/2002 determinou que todas as distribuidoras de energia do país deveriam

contratar energia via leilões públicos. Dessa forma desde 2004, ano da Instituição do Novo Modelo do setor elétrico (sustentado pelas Leis 10.847/2004, 10.848/2004 e pelo Decreto 5.163/04), quando o primeiro leilão após o Decreto 4.562/2002 foi feito, leilões de energia nova e existente têm sido feitos para suprir a demanda no ACR.

Conforme estabelecido no art. 11 do Decreto nº 5.163/2004 e no art. 2º da Lei nº 10.848/2004, as concessionárias, as permissionárias e as autorizadas de serviço público de distribuição de energia elétrica do Sistema Interligado Nacional (SIN) devem contratar a totalidade da demanda de seu mercado consumidor, por meio de leilões de energia realizados no ACR.

Os CCEARs são contratos que formalizam a contratação de energia por meio dos leilões realizados para o atendimento da demanda das distribuidoras, e são promovidos diretamente pela ANEEL ou por intermédio da CCEE, observando as diretrizes fixadas pelo Ministério de Minas e Energia (MME). Tais processos licitatórios contemplam tratamento para energia elétrica proveniente de empreendimentos de geração existentes, energia proveniente de novos empreendimentos de geração e fontes alternativas. O cronograma para a realização dos leilões tem por base o Ano "A", que corresponde ao ano previsto para o início do suprimento de energia elétrica adquirida pelas distribuidoras nos leilões, sendo divididos em: A-1, A-3 e A-5, ou seja, leilões realizados no primeiro, terceiro e quinto anos respectivamente anteriores ao Ano "A".

Para os Contratos de Compra de Energia no Ambiente de Contratação Livre (CCEALs), devem ser observadas as seguintes premissas:

1. Cada CCEAL é identificado como um relacionamento comercial entre um agente comprador e um agente vendedor;
2. O CCEAL é registrado no submercado de entrega da energia
3. A CCEE identificará os CCEALs e os respectivos limites relativos a agentes que tenham direito ao alívio de exposição, função da diferença de preços nos submercados origem e destino, por meio do eventual excedente financeiro apurado;
4. A realização da sazonalização e modulação do contrato são facultativas ao agente, exceto a modulação dos CCEALs firmados entre empresas do mesmo grupo econômico, onde o comprador pertence à categoria de distribuição, que serão realizadas conforme premissas específicas estabelecidas nesse documento;
5. Para CCEALs, os valores sazonalizados são considerados apenas com a validação das contrapartes.

2.4 Modelos do ONS e a Formação do PLD na CCEE

No Brasil as usinas produtoras de energia são despachadas centralizadamente pelo ONS e o preço do mercado de curto prazo, ou Preço de Liquidações das Diferenças (PLD), é estabelecido através de um software computacional pela CCEE.

Os modelos computacionais utilizados pelo ONS tem como principal objetivo o despacho hidrotérmico do SIN. Como o Brasil possui um parque gerador hidrotérmico, sendo as usinas hidrelétricas as mais representativas em capacidade instalada, a utilização desta prática é mundialmente consagrada.

Neste contexto, o custo de energia a ser produzido numa usina hidrelétrica não é medido diretamente. A metodologia utilizada baseia-se em um custo de oportunidade que resulta da otimização considerando a conexão das usinas hidrelétricas e térmicas e a transmissão entre elas, e principalmente, as economias de custo de combustível, ao se evitar a geração térmica, e o valor econômico de um possível corte de carga. O chamado custo da água representa esse custo de oportunidade que é derivado das decisões de usar mais água no presente, elevando-se o custo da energia no futuro com o uso dos reservatórios, podendo no limite chegar a um déficit de oferta no futuro ou usar menos água no presente, aumentando-se o custo atual da energia para poupar os reservatórios sob a pena de um poupança desnecessária, ou no limite de vertimento. O custo marginal de operação (CMO) é uma derivação deste conceito.

O ONS faz a programação da geração de cada usina do SIN, com a otimização dos recursos do sistema, na busca da minimização dos custos de operação, atendendo a demanda requisitada pela carga.

Fundamentalmente, devem ser observadas duas variáveis: o volume dos reservatórios e a tendência hidrológica do sistema. Quando existe um alto armazenamento nos reservatórios, os recursos hídricos são mais utilizados e economizam-se os recursos térmicos. Entretanto a tendência hidrológica é importante, pois prevendo uma afluência favorável - custo futuro baixo, a geração térmica será menos utilizada, e caso contrário, com a previsão de uma afluência desfavorável a geração térmica será mais utilizada.

Em resumo, no SIN o processo decisório passa pela possibilidade de utilização da energia com custo marginal teórico próximo de zero, armazenada nos reservatórios para atender à demanda, evitando os gastos de combustível nas térmicas, tendo em vista que a disponibilidade de hidrelétrica está limitada pela capacidade de armazenamento nos reservatórios. Dessa forma, existe a decisão operativa de hoje é dependente dos custos operativos esperados no futuro.

Na figura 2.4 é ilustrada uma situação de decisão simples, e é possível observar que a operação de um sistema hidrotérmico é um problema acoplado no tempo, de

forma que uma decisão operativa hoje, afeta o custo futuro do SIN. Isto é diferente dos sistemas puramente térmicos, nos quais a operação é desacoplada no tempo e as decisões seguem um padrão da teoria marginal de custos para atendimento da demanda (despacha-se as térmicas por ordem de custo crescente a medida que a carga aumenta).




Figura 2.4: *Processo de Decisão para Sistemas Hidrotérmicos*

A incerteza associada à futura vazão nos rios brasileiros, torna este problema probabilístico. O método de solução de problemas de otimização probabilísticos dotado para o sistema brasileiro foi a Programação Dinâmica Estocástica (PDE), que consiste no cálculo cumulativo do custo futuro, por inspeção, caminhando do futuro para o presente, para vários estados (energia armazenada e tendências históricas de vazões).

Na Figura 2.5 é apresentada uma ilustração de um exemplo muito simples, onde é possível notar o processo de cálculo do custo operativo (“custo de oportunidade”) por inspeção de um conjunto de séries futuras de energias afluentes. Neste caso são 8 séries, sendo que 1 resulta em déficit (risco de déficit = $1/8$), e as 7 demais séries atingem a capacidade máxima de armazenagem do sistema (vertimento – custo = 0) em diferentes estágios no tempo. Trajetórias de operação distintas, resultam 8 séries temporais de custos de operação, que trazidos a valor presente e ponderados ($1/8$), formam o CMO no instante inicial.




Figura 2.5: *Custo de Oportunidade e Cálculo do CMO*

O sistema brasileiro é notório pela grande quantidade de usinas e interligações, tornando impraticável o cálculo por inspeção na PDE, que verificaria um número exponencial de estados possíveis. Desta forma, o ONS adota uma cadeia de modelos de otimização baseadas em Programação Dinâmica Dual Estocástica (PDDE), que é um método que considera o uso de somente algumas trajetórias, em um processo iterativo de ida e volta (“forward” e “backward”). Em resumo, o método busca o uso ótimo da água armazenada, que corresponde ao ponto que minimiza a soma dos custos imediatos (determinativos) e os custos futuros (incertos e construídos por inspeção). O mínimo global é aquele onde as derivadas das funções do custo imediato e futuro são iguais - “valor da água”, conforme Figura 2.6.




Figura 2.6: Funções de Custo Futuro (FCF) e Imediato (FCI) x Armazenamento

Os modelos são aplicados para diferentes horizontes de decisões de planejamento da operação, que representam tipos distintos de impactos na performance do sistema: (i) efeitos de médio prazo - probabilidade de riscos de déficits futuros, valor esperado da geração térmica futura, etc.; (ii) efeitos de curto prazo - obtenção de metas semanais de geração das usinas, programas de manutenção, controle de cheias, restrições de segurança da rede, etc..




Figura 2.7: Cadeia de Modelos Computacionais

A Figura 2.7 ilustra a cadeia de modelos de otimização do despacho hidrotérmico do ONS, formado fundamentalmente pelos modelos NEWAVE e DECOMP . Os demais são modelos auxiliares para fornecimento de informações necessárias com frequências bem definidas.




Figura 2.8: *Modelo NEWAVE - Inputs e Outputs*

A entrada de dados (NEWAVE – 5 anos à frente e DECOMP – 12 meses à frente); é administrada pelo ONS e inclui dentre outros: a configuração hidráulica e térmica, as previsões de carga e de vazões; o estado dos reservatórios, as restrições operativas, as curvas de valor do risco de déficit, a curva de aversão ao risco (CAR) – vide figura 2.8. As saídas deste processo de cálculo mais importantes para o ONS são: as metas de geração; os intercâmbios e a Função Custo Futuro (FCF), que permite a conexão entre os modelos de otimização da cadeia – vide figura 2.8. Os custos marginais de operação (CMO) formam um conjunto de informações fornecidas ao final do processo de otimização do modelo, que é utilizado na sua busca da solução ótima ao longo processo. Em resumo, pode-se de forma simplificada dizer que são as derivadas no ponto ótimo, portanto bastante sensíveis à qualidade da solução.

O ONS semanalmente envia para a CCEE a entrada de dados dos modelos computacionais NEWAVE e DECOMP. Na CCEE é utilizado o procedimento de comercialização PdC PE.01 - Estabelecer Preço de Liquidação de Diferenças (PLD). Este PdC define basicamente: (i) para efeito de Contabilização, os dias a serem considerados serão somente os dias pertencentes ao Mês de Referência (M), descartando dias da semana operativa de meses anteriores (MA) e seguintes (MS); (ii) o cálculo do Preço ex-ante será realizado em base semanal, mesmo em situações em que a semana venha a avançar a fronteira do mês de apuração; (iii) Os PLD da semana são divulgados no site da CCEE sempre 1 dia útil antes de começar a semana operativa .

Os dados de entrada então se originam do ONS para simular NEWAVE e DECOMP na CCEE. No cálculo do PLD não são consideradas as restrições de transmissão internas a cada Submercado, para que a energia comercializada seja tratada como igualmente disponível em todos os pontos de consumo. A diferença de custo entre o despacho sem restrição e o despacho real é coberta pelo ESS, principalmente devido à variação da disponibilidade de energia nos pontos internos dos submercados. Quando o submercado estiver em racionamento, o cálculo do PLD neste contemplará o Custo do Déficit. Conforme Resolução ANEEL nº.377 de 30 de julho de 2003, que definiu a sistemática de cálculo do Preço Mínimo, esse é o menor valor do PLD (Pmin) permitido pela ANEEL. O valor é atualizado anualmente, na primeira semana operativa do mês de janeiro, pelo custo variável de Itaipu, sempre valorado pela média geométrica da taxa de câmbio do dólar do ano anterior. Por outro lado, o preço limite máximo (PLimite) é o maior do PLD, permitido pela ANEEL, e é definido como sendo o menor valor entre: (i) o preço estrutural da termelétrica mais cara no PMO – Programa Mensal de Operação – de janeiro do ano corrente; ou (ii) o preço máximo limite do ano anterior corrigido pelo IGP-DI acumulado entre novembro de um ano e novembro do ano consecutivo. A Resolução Homologatória ANEEL nº. 2002 de dezembro de 2015 definiu o preço limite como 422,56 R\$/MWh e o PLD_min como 30,25 R\$/MWh para todas as semanas operativas de 2016, para todos os submercados. Resumindo, a definição do PLD na CCEE pode ser obtida da seguinte forma abaixo:

Lembrando que, o CMO utilizado aqui é o obtido na CCEE com a relaxação de algumas restrições, apenas para fins de definição do PLD. Entretanto, se estas restrições não estiverem ativas o valor do PLD é praticamente igual ao CMO obtido pelo ONS. Fica claro neste momento a importância do ONS na formação do PLD na CCEE. Portanto, ao observarmos o comportamento do PLD, o mesmo retrata em muito a realidade ONS.

2.5 Testes com o PLD

O Preço de Liquidação das Diferenças (PLD) é o preço *spot* no mercado de energia elétrica brasileira. Mensalmente os *players* (comercializadoras, geradoras, distribuidoras e consumidores do mercado livre) com exposição (parcela long ou short dos portfólios de cada agente) tem suas posições liquidadas ao PLD. Basicamente, existem duas estratégias que um agente pode adotar: não ter nenhuma exposição ao mercado de curto prazo ou ter alguma exposição. O nível de exposição, é derivado da estratégia de comercialização de cada agente e depende da aversão ao risco e do momento de mercado. Em situações em que o PLD está muito alto, ou muito volátil o mercado tende a se proteger zerando suas exposições com contratos bilaterais de forma a não

incorrer em risco da variação do PLD.




Figura 2.9: *Histórico do PLD no subsistema SE/CO*

2.5.1 Teste da Distribuição dos Retornos

É importante a realização de um teste estatístico com base no histórico de retornos do PLD para o submercado SE/CO para o estudo de risco a fim de se determinar presença de assimetrias e eventos extremos.




Figura 2.10: *Histograma dos Retornos Históricos do PLD*

Através do histograma gerado pelo programa Eviews, é possível rejeitar a hipótese de que a distribuição dos retornos do PLD é normal já que a estatística Jarque-Bera é igual a 146,9706. Uma forma mais visual de comparar o histograma dos retornos do PLD é incluir no gráfico a normal teórica sobreposta ao histograma como na figura 2.11:




Figura 2.11: *Histograma com Normal Teórica dos Retornos Históricos do PLD*

Na literatura sobre comportamento de preços de *commodities* muito comumente é encontrado a característica de reversão à média. É importante, então verificar não só do ponto de vista de caracterização da série de preços, mas também, para a escolha de um modelo de simulação compatível com o comportamento dos preços se o PLD segue ou não a reversão à média. O processo mais simples de reversão a média é conhecido como Processo de Ornstein-Uhlenbeck descrito pela equação (2.1), ou seja, mudanças esperadas em x dependem apenas da diferença entre x e $\bar{x}$.

$$dx = \eta (\bar{x} - x) dt + \sigma dz \quad (2.1)$$

Além disso, um processo com reversão à média tem as seguintes características:

- Satisfaz as propriedades de Markov;
- Não possui incrementos independentes;
- $E[x_t] = \bar{x} + (x_0 - \bar{x}) e^{-\eta t}$;
- $V[x_t - \bar{x}] = \frac{\sigma^2}{2\eta} (1 - e^{-\eta t})$.

O software NEWAVE usado para previsão de preços de médio prazo (horizonte de 5 anos com discretização mensal) utiliza Programação Dinâmica Dual Estocástica. A determinação do PLD semanal é um *output* do encadeamento do Decomp, software usado para a operação de curto prazo (2 a 6 meses com etapas semanais), com o NEWAVE.

Uma questão relevante da formulação do NEWAVE é que os preços simulados convergem para a média em horizontes de tempo muitas vezes curtos (4 a 6 meses). Esta característica ocorre pelo fato de mesmo com entradas diferentes no modelo (por exemplo afluência mais alta nos primeiros 3 meses do horizonte modelado), o NEWAVE acaba convergindo o resultado para um ótimo comum. Este fato não é verdade quando são analisados choques permanentes dentro da janela temporal considerada na modelagem. Este fato será descrito mais a frente nos casos de sensibilidades tratados no modelo.

2.5.2 Estudo de Caso: Reversão à Média da Simulação pelo NEWAVE

Uma simulação feita com o NEWAVE na data 15/07/2016 para preços a partir do ano de 2017 foi feita com base em três cenários com premissas distintas:

- **Cenário Base:** ENA no Sudeste e Sul em dezembro de 2017 de 95% da MLT e Energia armazenada no SIN em 30% do total;

- **Cenário Pessimista:** ENA no Sudeste e Sul em dezembro de 2017 de 80% da MLT e Energia armazenada no SIN em 27% do total;
- **Cenário Otimista:** ENA no Sudeste e Sul em dezembro de 2017 110% da MLT e Energia armazenada no SIN em 33% do total.

O resultado da simulação pode ser visto na figura 2.12 e dois aspectos podem ser observados:




Figura 2.12: Rodada NEWAVE com Três Cenários

- Há uma convergência dos preços nos três cenários de hidrologia e da situação dos reservatórios para níveis estáveis quando se analisa os preços muitos meses à frente do mês inicial de simulação;
- Como ainda há uma sobreoferta estrutural de energia no sistema, visto que a expansão foi planejada sem levar em conta a recessão econômica dos anos de 2015 e 2016, os preços simulados para 2018 e 2019 ficam em patamares mais baixos. A relação carga/oferta de energia passa a impactar mais os preços quando a tendência hidrológica converge para a média e se projetam reservatórios com níveis de armazenamento muito mais estáveis operativamente.

Uma questão latente dessa reversão à média resultante da simulação utilizada para a geração de preços é se: historicamente o PLD reverte ou não a média. Caso não haja reversão a média, análises com um horizonte mais longo feitas através do NEWAVE podem ser de certa maneira refutadas visto que a realização ao longo do tempo não corresponde à saída do modelo.

2.5.3 Movimento Browniano Geométrico e Teste de Reversão à Média

O movimento browniano (processo de wiener) é um processo estocástico contínuo utilizado na modelagem de diferentes tipos de variáveis com variações estocásticas ao longo do tempo. É um processo análogo ao *random walk* em tempo contínuo e possui três características importantes:

- i É um processo de Markov;
- ii Possui incrementos independentes;
- iii Mudanças em um intervalo finito no tempo do processo possuem distribuição normal.

Um incremento infinitesimal de um processo browniano em tempo contínuo possui a seguinte formulação:

$$dz_t = \epsilon_t \sqrt{dt}, \text{ em que } \epsilon \sim N(0, 1) \quad (2.2)$$

O incremento $z(t) \sim N(0, t)$, sendo não estacionário e com variância explosiva. A equação (2.2) pode ser generalizada por um movimento browniano com presença de drift:

$$dx_t = \alpha dt + \sigma dz_t \quad (2.3)$$

em que, $dx_t \sim N(\alpha dt, \sigma^2 dt)$.

Um caso particular da generalização descrita na equação (2.3) é o Movimento Browniano Geométrico:

$$dx_t = \alpha x_t dt + \sigma x_t dz_t \quad (2.4)$$

A fim de estimar parâmetros do Movimento Browniano Geométrico para uma observação é necessário a discretização já que os dados das amostras encontram-se em tempo discreto. Essa transformação em tempo discreto é a seguinte:

$$\ln x_{t+1} - \ln x_t = \left(\alpha - \frac{1}{2} \sigma^2 \right) dt + \sigma (z_{t+1} - z_t) \quad (2.5)$$

$$\frac{\ln x_{t+1}}{\ln x_t} = \mu^* + \sigma e_t \quad (2.6)$$

em que:

- $z_t \sim N(0, t)$;
- $e_t \sim N(0, 1)$.

2.5.4 Teste de Raiz Unitária

Dada uma série de preços, testes comumente empregados para discernir se a série é melhor modelada por Movimentos Brownianos ou por Processos de Reversão à média são os testes de raiz unitária. É importante salientar que apesar de a teoria econômica muitas vezes conseguir descrever melhor processos por reversão à média, dificilmente há rejeição da hipótese de *random walk*. Um teste de raiz unitária bastante utilizado é o teste de Dickey-Fuller que partindo de uma equação

$$y_t = \alpha y_{t-1} + \mu_t \quad (2.7)$$

tem como hipótese nula:

$$H_0 : \alpha = 1$$

Utilizando a série de preços do PLD do submercado SE/CO descrita graficamente pela 2.9, fez-se o teste de Dickey-Fuller aumentado no software EViews e o resultado está descrito na tabela 2.4. A hipótese nula é rejeitada para os três níveis de significância (1%, 5% e 10%).

Tabela 2.4: *Teste Dickey-Fuller Aumentado: Série PLD SE/CO*

Null Hypothesis: D(LN__PT_) has a unit root		
Exogenous: Constant		
Lag Length: 0 (Automatic - based on SIC, maxlag=13)		
	t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic	-12.36665	0.0000
Test critical values: 1% level	-3.472813	
5% level	-2.880088	
10% level	-2.576739	

*Mackinnon (1996) one-sided p-values.

Corroborando ao resultado do teste da raiz unitária para histórico do PLD o fato de que o correlograma dos preços não apresenta uma tendência definida (não há decaimento nem crescimento das correlações) o que é outro indicativo da refutação da $H_0 : \alpha = 1$ como pode ser visto na figura 2.13.




Figura 2.13: Correlograma: Série PLD SE/CO

2.5.5 Modelagem final do PLD

É importante ressaltar que a determinação do preço *spot* no mercado de energia elétrica brasileiro é uma saída dos modelos oficiais. Diferente de outras commodities que têm seus preços determinados por diversos fatores não fundamentais como por exemplo a posição técnica dos *players* do mercado, o PLD é resultado dos modelos que por última instância dependem de variáveis endógenas, como por exemplo oferta e demanda de energia, afluência, nível dos reservatórios, entre outros. Como estas variáveis e o próprio modelo são fornecidos ao mercado e são os determinantes do PLD a melhor estimativa de tendência para avaliação de risco é o próprio modelo. As variáveis são semanalmente e mensalmente revisadas pelo ONS, o que faz com os resultados dos modelos mudem dinamicamente, ou seja, rodadas com um mês de diferença entre si usando os novos *input* oficiais darão um resultado diferente entre si.

O presente trabalho irá usar 6 diferentes sensibilidades dos principais inputs para que sejam capturadas tendência e dispersão para uma melhor avaliação do risco. Uma forma diferente de tratar o problema, seria fazer uma previsão dinâmica destas principais variáveis e rodar o NEWAVE de forma encadeada, ou seja, a saída de uma previsão fora do modelo (por exemplo fazer uma previsão da afluência futura diferente da previsão oficial) se tornaria a premissa do modelo no mês seguinte da rodada considerada. O NEWAVE seria, então, rodado novamente com estas novas premissas. Além de altamente complexa esta análise, computacionalmente seria muito ineficiente. Para exemplificação da complexidade computacional, uma rodada do NEWAVE leva em média mais de 1 hora, utilizando um computador com diversos processadores em paralelo.

Capítulo 3

Risco

Agentes de mercado estão expostos a basicamente dois tipos de risco: risco de financeiro e risco de mercado JORION (1997). Risco financeiro é basicamente derivado de perdas relacionadas às flutuações em variáveis que afetam o preço dos ativos financeiros, como: câmbio, preço das commodities, taxas de juros, preço de ações, entre outros. Risco de mercado são riscos incorridos pelas firmas no exercício de suas atividades visando criação de vantagem competitiva e construção de valor para seus acionistas. Este tipo de risco é dependente das decisões de administração bem como do tipo de mercado que cada firma atua.

O presente estudo busca a utilização da medida de risco CVaR na formulação da otimização de portfólio para o setor elétrico brasileiro. Uma das medidas de risco mais famosas e amplamente mais utilizadas pelo mercado financeiro é o VaR JORION (1997). Porém o VaR é uma medida coerente de risco apenas quando ele é baseado em distribuições normais, sendo então, proporcional ao desvio padrão. Além disso vale ressaltar que otimizações com VaR são difíceis de serem feitas quando há o emprego de geração de cenários ROCKAFELLAR e URYASEV (2002). Em alguns casos o VaR pode ter um mal comportamento gerando múltiplos extremos locais, o que é um grande empecilho quando se trata da otimização de portfólios e obtenção de um *mix* ótimo de ativos ROCKAFELLAR e URYASEV (2000).

O gerenciamento de risco se dá pela implementação de rotinas para identificar, medir e gerenciar os riscos financeiros JORION (1997). Existem diversas medidas de risco, cada uma com características específicas. Algumas medidas, como *stop-loss limits* são medidas ex-post, ou seja, prescrevem uma ação de parada após a ocorrência de um evento (por exemplo o rompimento de uma barreira de preço).

Para que o gerenciamento de risco seja efetivo é necessário que a análise de risco seja feita *ex ante* ou que ela seja feita com controles *forward looking*. O gestor de risco precisa identificar os fatores de risco e quantificar perdas potenciais consequentes da

volatilidade destes fatores de risco. Para o caso do *valuation* de uma firma, o primeiro passo é a determinação do valor da mesma com base em premissas. O passo seguinte é analisar como variações nessas premissas impactam o valor da mesma (análise de sensibilidade). Uma outra abordagem é calcular como o valor da mesma varia de acordo com a variação de uma premissa. Esse mesmo conceito pode ser aplicado a um ativo financeiro ou a um portfólio de ativos financeiros. Essa análise não consegue capturar os riscos de maneira satisfatória uma vez que não considera a volatilidade dos fatores de risco e a correlação entre eles. Medidas de sensibilidade não são aditivas e, portanto, não conseguem fazer agregação de risco e representar o mesmo como uma perda financeira.

3.1 Desvio Padrão

O artigo clássico de MARKOWITZ (1952) introduziu o conceito de que os investidores deveriam considerar o retorno esperado do portfólio como sendo desejável e a variância do retorno como algo indesejável. Além disso, Markowitz divide em duas etapas o processo da decisão de investimento para um investidor: (i) o primeiro estágio dependente da observação e experiência com os ativos disponíveis e os ensejos quanto às suas performances futuras; e (ii) o segundo estágio referente às expectativas de retorno futuras mais firmes e posterior escolha do portfólio.

O retorno de um portfólio composto por 2 ativos é igual a

$$R_p = w_1 r_1 + w_2 r_2 \quad (3.1)$$

em que R_p é o retorno do portfólio, X_i é o peso do ativo i e r_i é o retorno do ativo i . Assim, o retorno esperado para esse portfólio é igual a

$$E(R_p) = X_1 E(r_1) + X_2 E(r_2) \quad (3.2)$$

A variância do portfólio é dada por:

$$\sigma_p^2 = X_1^2 \sigma_1^2 + X_2^2 \sigma_2^2 + 2X_1 X_2 \text{Cov}(r_1, r_2) \quad (3.3)$$

Assumindo que $X_1 + X_2 = 1$ e que não se admite uma posição *short* em nenhum ativo, isso implica que $X_2 = 1 - X_1$ então pode-se reescrever a equação (3.3) em função de X_1 .

$$\sigma_p = [(X_1^2 \sigma_1^2 + (1 - X_1)^2 \sigma_2^2 + 2X_1 X_2 \text{Cov}(r_1, r_2))]^{1/2} \quad (3.4)$$

Derivando o desvio padrão do portfólio com relação a X_1 e igualando a zero, o peso X_{min} que minimiza a variância do portfólio é dado por:

$$X_{min} = \frac{\sigma_1^2 - Cov(r_1, r_2)}{\sigma_1^2 + \sigma_2^2 - 2Cov(r_1, r_2)} \quad (3.5)$$

Assim, os pesos dos ativos que minimizam a variância devem ser iguais a: $X_1 = X_{min}$ e $X_2 = 1 - X_{min}$.

Esse exemplo de minimização de variância com dois ativos pode ser estendido para n ativos porém o cálculo torna-se demasiadamente complexo e há necessidade de programação não-linear para a solução desse problema. O problema estendido para n ativos está descrito nas equações abaixo:

$$Minimizar V(X) = \sum_j^n \sum_i^n X_i X_j \sigma_{ij} \quad (3.6a)$$

Sujeito a:

$$\sum_i^n X_i E(r_i) = R^* \quad (3.6b)$$

$$\sum_i^n X_i = 1 \quad (3.6c)$$

$$x_i \geq 0 \quad (3.6d)$$

Em que:

σ_{ij} é a covariância entre os ativos i e j ;

R^* é o retorno objetivo do problema de minimização;

n é o número de ativos.

3.2 VaR

Como descrito anteriormente, análises de sensibilidade não conseguem agregar riscos e representar os mesmos como perdas financeiras. O *Value-at-Risk*(valor em risco) ou simplesmente VaR consegue combinar variações desses fatores de risco com a probabilidade de movimentos de mercado adversos. Por ser dependente de probabilidades, o VaR é uma medida de risco estatística das perdas potenciais. O VaR pode ser definido de duas maneiras:

- i Perda potencial no valor de uma carteira, dado um horizonte temporal e um nível de significância;
- ii Perda máxima no valor de uma carteira dado um horizonte temporal e intervalo de confiança.

Para ilustrar a interpretação dessa medida, digamos que uma comercializadora após o cálculo do VaR para 1 dia com intervalo de confiança de 95% encontre um valor igual a R\$ 10.000.000,00. Isso significa que de um dia para o outro com 5% de significância, a comercializadora pode perder R\$ 10.000.000,00. Alternativamente, em uma janela de n dias, a comercializadora pode perder R\$ 10.000.000,00 em 5% das observações ($5\% * n$ dias).

3.3 CVaR

Antes de caracterizar o CVaR é importante descrever o que é uma medida de risco coerente. Para que uma medida de risco seja considerada coerente ela deve ter as seguintes características se χ é um espaço linear de funções mensuráveis que definem as variáveis aleatórias que representam as perdas financeiras do espaço de probabilidade definido por (Ω, Ψ, P) e $\rho: \chi \rightarrow \mathbb{R}$ é uma medida de risco coerente, então ARTZNER *et al.* (1999):

- I ρ deve ser Monótona: $X \leq Y \Rightarrow \rho(Y) \leq \rho(X), \forall X, Y \in \chi$
- II ρ deve ser Relevante: $X \geq 0$, então $\rho(X) \leq 0, \forall X \in \chi$
- III ρ deve ser Sub-aditiva: $\rho(X + Y) \leq \rho(X) + \rho(Y), \forall X \in \chi$ e $\lambda > 0$
- IV ρ deve ser Homogênea Positiva: $\rho(\lambda X) = \lambda \rho(X), \forall X \in \chi$ e $\lambda > 0$
- V ρ deve ser Transladável: $\rho(X + a) = \rho(X) + a, \forall X \in \chi$ e $a \in \mathbb{R}$

O VaR não é uma medida de risco coerente porque para a combinação de dois portfólios o VaR do portfólio resultante pode ser maior que a soma dos riscos individuais de cada portfólio (quebra da Sub-aditividade), além disso, ele é não convexo e pode possuir mínimos locais, o que dificulta a otimização. O CVaR, também conhecido como *Expected Shortfall*(ES) para funções contínuas, além de ser uma medida de risco coerente, ele captura eventos extremos o que é extremamente importante na análise de risco quando trata-se de distribuições com caudas pesadas. Enquanto que o VaR corresponde ao percentil de uma distribuição, o CVaR é a perda esperada para valores de

perda maiores que o VaR. Além disto, o VaR tem um viés otimista ao invés de apresentar um conservadorismo que deveria ser esperado na gestão de riscos ROCKAFELLAR e URYASEV (2002). A partir das contribuições do trabalho publicado por R.T. Rockafellar and S.P. Uryasev (2000) o CVaR ganhou mais notoriedade como medida de risco. Para funções contínuas, o CVaR pode ser definido genericamente como:

$$CVaR(\alpha) = E[-x | -x \leq -VaR] \quad (3.7)$$

Ou seja, para distribuições contínuas dado um nível de confiança o CVaR é igual ao valor esperado da perda seja maior ou igual ao VaR.

Na otimização de carteiras o CVaR tem vantagens sobre o VaR. Ele mantém os resultados do VaR para distribuições normais, sendo equivalente otimizar esses portfólios normais trabalhando com média variância, CVaR ou VaR ROCKAFELLAR e URYASEV (2000). Para distribuições não normais, o CVaR leva em conta a diferença de peso dos eventos de perda extremos ao invés de dar o mesmo peso para as caudas como no caso da otimização por média variância. Soma-se a isso que a otimização com CVaR se dá através de uma fórmula, relativamente simples, tratada mais adiante com uma formulação tanto para distribuições contínuas quanto para distribuições discretas.

Na análise de risco com simulações, distribuições discretas são geradas e o CVaR tratar estes casos, enquanto o VaR apresenta deficiências.

Para distribuições discretas e/ou com descontinuidades, casos mais relevantes nos tratamentos de simulação, o CVaR tem uma definição um pouco não tão direta. Deve-se então definir duas medidas: o $CVaR^+$ e o $CVaR^-$. Generalizando, $CVaR^- \leq CVaR \leq CVaR^+$. Quando a distribuição de retornos não tem um salto ("jump") no limite do VaR a igualdade ocorre, porém em modelos de simulação de cenário a igualdade nunca ocorre ROCKAFELLAR e URYASEV (2002).

O CVaR é na realidade uma média ponderada entre o VaR e o $CVaR^+$.

$CVaR^-$, ou $\alpha-CVaR^-$ é definido como:

$$\phi_{\alpha}^-(x) = E\{f(x, y) | f(x, y) \geq \zeta_{\alpha}(x)\} \quad (3.8)$$

$CVaR^+$, ou $\alpha-CVaR^+$, também conhecido como *Expected Shortfall* ou *Mean Excess Loss* é definido como:

$$\phi_{\alpha}^+(x) = E\{f(x, y) | f(x, y) > \zeta_{\alpha}(x)\} \quad (3.9)$$

A relação entre as medidas de risco é a seguinte: $VaR \leq CVaR^- \leq CVaR \leq CVaR^+$. A igualdade ou desigualdade depende da divisão do ponto extremo α no cálculo das medidas supramencionadas, uma vez que a distribuição agora considerada é discreta.

O α -CVaR formulado como uma média ponderada é igual a:

$$\phi_\alpha = \lambda_\alpha \zeta_\alpha(x) + [1 - \lambda_\alpha(x)] \phi_\alpha^+(x) \quad (3.10)$$

em que,

$$\lambda_\alpha(x) = \frac{\Psi(x, \zeta_\alpha(x)) - \alpha}{1 - \alpha} \quad (3.11)$$

Então, o α -CVaR é igual uma média ponderada entre o α -VaR e o α -CVaR⁺ com pesos de ponderação iguais a λ_α e $1 - \lambda_\alpha$ respectivamente. A variável $\Psi(x, \zeta_\alpha(x))$ é a distribuição acumulada calculada das perdas calculada no valor do VaR, ou de forma alternativa, $\Psi(x, \zeta_\alpha(x)) = \Psi(\text{VaR})$, que é a probabilidade que as perdas não sejam maiores ou iguais ao VaR. Para o caso em que distribuição de probabilidade das perdas não tem descontinuidade o α -CVaR = α -CVaR⁺:

$$\Psi(x, \zeta_\alpha(x)) = \alpha \Rightarrow \lambda_\alpha(x) = 0 \Rightarrow \phi_\alpha = \phi_\alpha^+(x)$$

Um característica interessante para o tratamento de otimizações é que o α -CVaR é convexo, enquanto o α -VaR, α -CVaR⁻ e α -CVaR⁺ não são necessariamente convexas.

3.3.1 Exemplo de Comparação entre VaR e CVaR

Uma vantagem do CVaR em relação ao VaR é que para distribuições não normais o CVaR consegue capturar melhor riscos extremos. Para exemplificar esse fato, gerou-se uma distribuição com 100.000 valores que se aproxima bastante da normal padrão como pode-se observar pela figura 3.1:




Figura 3.1: *Histograma da Simulação de Retornos Normais*

Com essa distribuição, calculou-se o VaR e o CVaR para os três diferentes níveis de significância padrões (1%, 5% e 10%). O VaR também foi calculado através da aproximação apresentada na equação . Os resultados e o erro percentual entre o VaR calculado pelo percentil e o VaR aproximado ($VaR = \sigma \times \Phi(\alpha)$, em que σ é o desvio padrão da distribuição dos retornos e $\Phi(\alpha)$ é a normal padrão inversa relativa ao intervalo de confiança α) encontram-se nas tabelas 3.1, 3.2 e 3.3:

Gerou-se uma segunda distribuição de retornos com a calda esquerda mais pesada, vide figura 3.2 . Os resultados encontram-se na tabela :




Figura 3.2: *Histograma da Simulação de Retornos com Cauda Esquerda Pesada*

Tabela 3.1: VaR e CVaR para uma simulação Genérica de Retornos com Nível de Significância de 10%

	VAR(90%)	CVAR(90%)
Cauda normal	0,30	0,41
Cauda Pesada	0,49	0,72

Tabela 3.2: VaR e CVaR para uma simulação Genérica de Retornos com Nível de Significância de 5%

	VAR(95%)	CVAR(95%)
Cauda normal	0,38	0,48
Cauda Pesada	0,71	0,85

Tabela 3.3: VaR e CVaR para uma simulação Genérica de Retornos com Nível de Significância de 1%

	VAR(99%)	CVAR(99%)
Cauda normal	0,54	0,61
Cauda Pesada	0,94	0,97

Tabela 3.4: Erro Percentual do Cálculo do VaR Aproximado para o Nível de Significância de 5%

	VAR(95%)	VAR Aproximado(95%)	Erro Percentual
Cauda normal	0,38	0,38	0,21%
Cauda Pesada	0,71	0,50	40,43%

3.4 Otimização do CVaR

Para distribuições contínuas, o α -VaR e o α -CVaR para uma variável aleatória de perda x a um nível de probabilidade $\alpha \in (0, 1)$ são definidos pelas equações (3.12) e (3.13) respectivamente.

$$\zeta_\alpha(x) = \min\{\zeta \in \mathbb{R} : \psi(x, \zeta) \geq \alpha\} \quad (3.12)$$

$$\phi_\alpha(x) = \frac{1}{1 - \alpha} \int_{f(x, y) \geq \zeta_\alpha(x)} f(x, y) p(y) dy \quad (3.13)$$

Na equação (3.12), $\zeta_\alpha(x)$ é o ponto esquerdo extremo do intervalo não vazio que consiste nos valores de ζ tais que $\psi(x, \zeta) = \alpha$. Na segunda fórmula, a probabilidade associada ao evento $f(x, y) \geq \zeta_\alpha(x)$ é igual a $1 - \alpha$. Segue, que $\phi_\alpha(x)$ é a expectativa condicional da perda associada a x relativa à perda sendo $\zeta_\alpha(x)$ ou maior. Pode-se então definir uma função que caracteriza conjuntamente as duas medidas $\phi_\alpha(x)$ e $\zeta_\alpha(x)$ no plano $X \times \mathbb{R}$:

$$F_\alpha(x, \zeta) = \zeta + \frac{1}{1 - \alpha} \int_{y \in \mathbb{R}^n} [f(x, y) - \zeta]^+ p(y) dy \quad (3.14)$$

em que $[t]^+ = \max\{t, 0\}$, ou seja valores não negativos. É possível se demonstrar que minimizar α -CvaR é equivalente a minimizar $F_\alpha(x, \zeta)$, além disso a minimização de $F_\alpha(x, \zeta)$ é convexa. A discretização do problema de minimização segue a seguir.

Seja o vetor de decisão $x = (x_1, \dots, x_n)$ sendo o peso do ativo i tal que o portfólio

obedeça:

$$x_i \geq 0 \text{ para } i = 1, 2, \dots, n, \text{ tal que } \sum_{i=1}^n x_i = 1. \quad (3.15)$$

Seja y_i o retorno do ativo i a função que descreve o retorno do portfólio é dada por:

$$f(x, y) = -[x_1 y_1 + \dots + x_n y_n] = -x^T y. \quad (3.16)$$

Sejam agora m e V a média e a variância de y , essas medidas para o portfólio são iguais a

$$\mu(x) = -x^T m, \sigma^2 = x^T V x. \quad (3.17)$$

Deve-se definir os portfólios que gerem um retorno mínimo R que satisfaz a equação:

$$\mu(x) \leq -R \quad (3.18)$$

Os portfólios factíveis são aqueles que:

$$X = \{x : x \text{ satisfaz (3.15) e (3.18)}\}. \quad (3.19)$$

A minimização de $F_\alpha(x, \zeta)$ passa a minimização de:

$$\tilde{F}_\alpha(x, \zeta) = \zeta + \frac{1}{q(1-\alpha)} \sum_{k=1}^q [-x^T y_k - \zeta]^+. \quad (3.20)$$

A minimização de $\tilde{F}_\alpha$ em $X \times \mathbb{R}$ para ser uma aproximação da minimização de F_α em $X \times \mathbb{R}$ pode ser reduzida para programação linear. Utilizando variáveis auxiliares u_k para $k = 1, \dots, q$ a minimização da equação (3.20) é equivalente a:

$$\zeta + \frac{1}{q(1-\zeta)} \sum_{k=1}^q u_k \quad (3.21)$$

sujeita às restrições (3.15) e (3.18) e

$$u_k \geq 0 \text{ e } x^T y_k + \zeta + u_k \geq 0 \text{ para } k = 1, \dots, q. \quad (3.22)$$

Capítulo 4

Otimização de Carteiras

A abordagem aqui utilizada considerou o retorno de um ativo com base no valor presente ("VP") do mesmo. Na maioria dos contratos bilaterais do mercado brasileiro o pagamento e/ou recebimento pela energia comprada ou vendida é mensal, ou seja, o fluxo de caixa de uma carteira é mensal. Dessa forma, é importante avaliar na simulação o caminho percorrido já que o VP do ativo i vai depender do mesmo. Um agente do setor elétrico que negocia energia basicamente tem duas decisões:

- Ter exposição ao mercado de custo prazo, ou seja, ao PLD;
- Não ter exposição ao PLD.

Em momentos de grande volatilidade do mercado, muitos agentes por aversão ao risco acabam preferindo zerar sua exposição ao PLD comprando ou vendendo contratos bilaterais. Esses contratos, que geralmente são negociados a preço fixo, tendem a se valorizar nesses momentos de alta volatilidade, não só por questões de níveis de PLD mas também pelo aumento da demanda por proteção. Definindo-se em um portfólio básico, com o único fator de risco sendo o PLD (existem outros fatores de risco no mercado que serão abordados posteriormente), o valor presente do contrato a preço fixo é igual a

$$VP = \sum_{k=1}^{k=n} \frac{1}{(1+r)^k} Precofixo \quad (4.1)$$

em que r é a taxa de desconto, k é o número de meses para o vencimento do contrato e $Precofixo$ é o preço do contrato. O contrato a preço fixo possui correção por índices de inflação (IPCA ou IGP-M dependendo do contrato) anuais, uma vez ao ano.

4.0.1 Ativos da Carteira Considerada

Os ativos passíveis de serem incluídos no portfólio de 5 anos que será otimizado são os seguintes:

- Contrato bilateral de 1 ano de duração com início no mês do estudo;
- Contrato bilateral de 2 anos de duração com início no mês do estudo;
- Contrato bilateral de 3 anos de duração com início no mês do estudo;
- Contrato bilateral de 4 anos de duração com início no mês do estudo;
- Contrato bilateral de 1 ano de duração durante os últimos 12 meses do estudo;
- Contrato bilateral de 2 anos de duração durante os últimos 24 meses do estudo;
- Contrato bilateral de 3 anos de duração durante os últimos 36 meses do estudo;
- Contrato bilateral de 4 anos de duração durante os últimos 48 meses do estudo;
- Contrato a PLD;

No mercado de energia elétrica brasileiro existem diversos outros ativos disponíveis como opções, swaps, etc. Porém, considerou-se apenas dois tipos de ativos não só como uma hipótese simplificadora, mas também por serem os mais líquidos do mercado. Vale ressaltar que o Contrato a PLD aqui mencionado não considera nenhum tipo de ágio ou deságio (presentes no mercado e dependentes de fatores como liquidez) e que não há custo de transação envolvendo a compra dos mesmos.

O custo ou receita com um contrato bilateral são definidos da seguinte forma:

$$Custo_{bil} = V_{bil} \times t_{bil,k} \times P_{C,bil,k} \quad (4.2)$$

$$Receita_{bil} = V_{bil} \times t_{bil,k} \times P_{V,bil,k} \quad (4.3)$$

Em que:

$Custo_{bil}$ é o custo de um contrato bilateral

$Receita_{bil}$ é a receita obtida com a venda de um contrato bilateral

V_{bil} é o volume (MWh) de um contrato bilateral

$t_{bil,k}$ é o tempo em horas de um contrato bilateral

$P_{C,bil,k}$ é o preço (R\$/MWh) de um contrato bilateral de compra

$P_{V,bil,k}$ é o preço (R\$/MWh) de um contrato bilateral de venda

Portanto, a Receita Líquida é definida por:

$$ReceitaLiq_{bil} = V_{bil} \times t_{bil,k} \times (P_{V,bil,k} - P_{C,bil,k}) \quad (4.4)$$

A receita com um contrato a PLD é igual a:

$$Receita_{spot} = V_{spot} \times t_{spot} \times P_{spot,k} \quad (4.5)$$

Em que:

$Receita_{spot}$ é a receita obtida com a venda de energia elétrica no mercado *spot*

V_{spot} é o volume (MWh) de um contrato no mercado *spot*

t_{spot} é o tempo em horas de um contrato a PLD

$P_{spot,k}$ é o preço (R\$/MWh) de um contrato bilateral

4.1 Estudo de Caso

É importante ressaltar que a receita ou custo gerado pela estratégia de contratação é mensal, ou seja, o agente paga ou recebe valores mensalmente. Utilizando a saída do modelo NEWAVE com seus 2000 cenários para 60 meses de horizontes (matriz 2000 x 60) para cada sensibilidade considerada no estudo, é interessante que seja utilizado uma medida que possa agregar as séries pertencentes a matriz em um vetor de dimensão (2000 x 1) para cada cenário de sensibilidade. Uma forma simples de tratar esse problema é através do Valor Presente dos fluxos de caixa gerados por cada cenário. Assim, é possível transformar a matriz em um vetor e realizar a otimização.

Os cenários de sensibilidade para fins de otimização com restrições de risco estão descritos abaixo:

Cenário 1: PMO de janeiro de 2017 ("Caso Base");

Cenário 2: PMO de janeiro de 2017 tendência hidrológica pessimista ("Hidrologia Baixa");

Cenário 3: PMO de janeiro de 2017 com tendência hidrológica otimista ("Hidrologia Alta");

Cenário 4: PMO de janeiro de 2017 com choque de carga permanente de + 5% em relação ao Caso Base ("Carga 5%");

Cenário 5: PMO de janeiro de 2017 com choque de carga permanente de + 10% em relação ao Caso Base ("Carga 10%");

Cenário 6: PMO de janeiro de 2017 com carga estática ("Carga Estática");

O Programa Mensal de Operação (PMO) é elaborado pelo ONS e os estudos realizados em base mensal fornecem metas e diretrizes a serem seguidas pelos órgãos executivos da Programação Diária da Operação Eletroenergética e da Operação em Tempo Real ONS (2016). Além disso, o PMO fornece as informações de entrada com as premissas utilizadas para que os agentes possam realizar suas simulações de preços futuros nos softwares. É divulgado então um arquivo com essas premissas chamado de "deck". As premissas exógenas ao modelo que geram risco e de difícil previsão são: as afluições e a carga. A oferta de energia foi excluída para efeito dos estudos das sensibilidades por se entender que o monitoramento de obras e o planejamento da expansão de oferta deveria refletir a realidade futura.

Uma das limitações provenientes do NEWAVE é que as séries sintéticas de hidrologia convergem relativamente rápido para a média de 100% da MLT, aproximadamente no terceiro ano de simulação, o que acaba limitando a dispersão das séries simuladas após essa reversão. Essa convergência pode ser vista na figura 4.1. O problema da dispersão dos cenários foi contornado através da simulação dos 6 cenários modelados.

O Caso Base é gerado a partir do *deck* oficial de janeiro de 2017 do PMO de janeiro. O caso Hidrologia Baixa é gerado com um choque negativo de 25% na afluição dos meses utilizados como base no modelo autorregressivo periódico PAR(p), gerando uma tendência de afluições futuras mais baixas. O caso Hidrologia Alta é gerado com um choque positivo de 25% na afluição dos meses utilizados como base no modelo PAR(p), gerando uma tendência de afluições futuras mais altas. O caso Carga 5% e Carga 10% foram gerados com um choque de 5% e 10% nas cargas do *deck* oficial. E por último, o caso Carga Estática foi gerado replicando a carga de 2017, mantidas as suas sazonalidades mensais para os 4 anos restantes de estudo.

O problema aqui proposto é otimizar a escolha do portfólio de um agente que necessita contratar sua energia em um horizonte de 5 anos. Ele possui basicamente duas escolhas: comprar um contrato a preço fixo ou comprar um contrato a PLD. Dependendo do nível do PLD futuro projetado, pode ser interessante ter alguma exposição ao mesmo, porém o PLD insere muito risco por ser extremamente volátil o que implica na necessidade de uma criteriosa análise de risco.

Com base nestas sensibilidades, a figura 4.1 mostra o efeito das mesmas no preço ao longo do horizonte de estudo.

A metodologia empregada foi empilhar as matrizes de preço de cada cenário descrito (cada uma com dimensão 2.000×60), de forma a se obter uma matriz de dimensão 10.000×60 e calcular o valor presente da receita dos diferentes ativos com base nessa matriz, formando então um vetor de dimensão 10.000×1 . Assim, 9 vetores de mix de contratos bilaterais com PLD são obtidos (representados por cada um dos ativos supramencionados). Esses vetores servirão de dados de entrada para a otimização com minimização do CVaR e para a otimização de Média Variância. O próximo passo é transformar esses vetores que contém valores presentes em funções dos 10.000 cenários de preços gerados, em vetores que contém retornos. Os retornos são então calculados como sendo a economia percentual do valor presente dos ativos considerados comparada ao valor presente de um contrato fixo de 5 anos. O problema é análogo para o caso em que uma comercializadora deseja vender a energia que tem em seu portfólio. O retorno neste caso é o ganho percentual em função do valor presente do custo da energia já contratada.




Figura 4.1: Média das Séries do NEWAVE

4.2 Resultados da otimização

A otimização implementada através do Matlab foi feita através do objeto "PortfolioC-VaR" que permite a caracterização do problema e já possui um solver embutido. Os mesmos resultados poderiam ter sido obtidos com uma transcrição fiel da equação (3.20) como função objetivo, usando uma função de otimização nativa do Matlab como a "fmincom". Por uma questão de robustez, optou-se em usar a via nativa do Matlab para a otimização, apesar dos resultados serem os mesmos.

Implementando o *script* de Matlab do Anexo A considerando o intervalo de confiança de 95% com os ativos descritos encontramos a seguinte fronteira eficiente que relaciona o valor esperado dos retornos com o CVaR dos portfólios ótimos como mostra a figura 4.2.




Figura 4.2: *Fronteira Eficiente CVaR*

A otimização de portfólio pelo critério de média variância tem como resultado uma fronteira eficiente que relaciona o valor esperado dos retornos com o desvio padrão dos portfólios ótimos como mostra a figura 4.3.




Figura 4.3: *Fronteira Eficiente Média Variância*

Pode-se calcular o CVaR dos portfólios ótimos pela ótica da média variância e o desvio padrão dos portfólios ótimos pela ótica da minimização do CVaR. Dessa forma, constroem-se dois gráficos sobrepondo as fronteiras eficientes para que seja possível comparar visualmente a diferença entre os resultados das otimizações. A figura 4.4 apresenta a fronteira eficiente relacionando os retornos esperados com o CVaR para os dois métodos de otimização em questão e a figura 4.5 apresenta a fronteira eficiente relacionando os retornos esperados com o desvio padrão para os dois métodos de otimização em questão.




Figura 4.4: *Fronteiras Eficientes: $E[R] \times CVaR$*




Figura 4.5: *Fronteiras Eficientes: $E[R] \times \sigma$*

As duas otimizações geram alocações de ativos diferentes entre si, uma vez que o retorno dos portfólios não é normal como visto pela figura 4.6 em linha com ROCKAFELLAR e URYASEV (2000).




Figura 4.6: *Histograma Retornos*

A figura 4.7 mostra a alocação dos ativos para as duas otimizações variando o retorno esperado. Percebe-se uma diferença nesta alocação para os dois métodos de otimização uma vez que os retornos não são normais.




Figura 4.7: Alocação dos Ativos nos Portfólios Ótimos

Em princípio o *mix* de contratos resultado da otimização do CVaR insere um pouco mais de volatilidade ao portfólio como mostra a figura 4.5, como era de se esperar uma vez que a otimização de média variância minimiza a volatilidade, porém o CVaR se mostra naturalmente mais baixo em boa parte dos portfólios avaliados como mostra a figura 4.4, ambos resultados em linha com as conclusões obtidas por KROKHMAL *et al.* (2002).

Ressalta-se que apesar de uma certa proximidade dos dois métodos, a inserção de instrumentos como opções que não foram tratados nesse trabalho poderia gerar distribuições ainda mais discrepantes da distribuição normal e portanto, resultados das otimizações mais discrepantes entre os dois métodos aqui tratados KROKHMAL *et al.* (2002).

É importante destacar a assimetria da distribuição dos retornos como mostra a figura 4.6, sugerindo que a proteção contra perdas extremas, gerada pela alocação ótima de minimização do CVaR, é extremamente significativa em termos financeiros. Um pequeno desvio para a esquerda da distribuição poderia gerar graves perdas financeiras, e como o CVaR é mais conservador por diferenciar o peso das caudas da distribuição ele é o método mais indicado uma vez que a distribuição dos preços do PLD gerada pelo NEWAVE não é normal (vide o teste a seguir).

4.2.1 Teste de Normalidade

Para a simulação tratada, fez-se o teste Jarque-Bera para todos os ativos avaliados. Para os 3 níveis de significância usuais (1%, 5% e 10%) todos os ativos tem distribuições em que não se rejeita a normalidade. Esse fato corrobora com a abordagem da utilização do CVaR.

4.2.2 Otimização com IC de 99%

A comparação entre as otimizações com níveis de confiança de 5% e 1% está apresentada na figura 4.8. Como era esperado, a diminuição do nível de confiança desloca significativamente a fronteira eficiente para a direita, ou seja, a otimização passa a ser consideravelmente mais conservadora. A diferença entre as fronteiras eficientes para os dois métodos tratados aumenta para o nível de confiança de 1%.




Figura 4.8: Fronteiras Eficientes CVaR - $\alpha = 95\%$ e $\alpha = 99\%$

Capítulo 5

Conclusões

Esta dissertação atingiu seu objetivo de tratar o problema da otimização de carteiras de energia elétrica no Brasil com minimização do CVaR. Além disto fez-se a comparação desta abordagem com a da otimização pela ótica da média variância.

No capítulo 2 o mercado de energia elétrica brasileiro foi contextualizado. Uma explanação sobre os modelos computacionais e o preço *spot* foi feita, além de testes com o PLD. Pôde-se mostrar que o PLD não possui uma distribuição normal e que apesar do NEWAVE ter uma tendência de gerar preços que convergem para a média no médio, longo prazo, com 3 diferentes premissas de hidrologia, estudando-se o comportamento do PLD realizado, rejeita-se a hipótese de reversão à média. Apesar disso, optou-se por usar o NEWAVE como gerador de cenários para a análise dos portfólios uma vez que ele apontaria melhor a tendência do comportamento de preços futuros se comparado a uma geração de cenários como a do método de Monte Carlo, fato explicado pelo PLD ser gerado pelo NEWAVE. A fim de conseguir embutir no estudo dispersões além do caso base do PMO de janeiro de 2017, implementou-se as sensibilidades descritas na seção 4.1.

Mostrou-se a vantagem do CVaR sobre o VaR para distribuições de retornos não normais. No exemplo de comparação entre VaR e CVaR na seção 3.3.1 as duas medidas foram calculadas para uma distribuição normal e uma distribuição com cauda esquerda pesada e pôde-se constatar o conservadorismo oportuno do CVaR para o dimensionamento do risco. É importante observar que assim como o VaR, o CVaR tem a característica de quantificar o risco com apenas um número com significado financeiro, o que facilita a sua interpretação.

A otimização com minimização do CVaR provou-se mais conservadora em comparação com a otimização de média variância.

Capítulo 6

Trabalhos Futuros

Como hipótese simplificadora o presente trabalho considerou apenas dois tipos de ativos para compor o portfólio: contrato a preço fixo e contrato PLD. Como extensão do presente trabalho, seria natural acrescentar mais possibilidades de ativos para o estudo de otimização. Avaliar o uso de opções, compra e venda em diferentes sub-mercados, swaps, entre outros. Seria desejável fazer a análise dinâmica do presente estudo, ou seja, fazer um estudo de mudança de alocação ao longo da janela temporal considerada. Uma outra análise interessante seria fazer um backtesting dos portfólios escolhidos para fins de comparação do resultado do modelo com o realizado, inclusive comparando com o portfólio de média variância.

Não se considerou na otimização realizada limites de capital de giro mensais, o que poderia gerar alocações diferentes, portanto recomenda-se que tais limites sejam considerados em trabalhos futuros.

Uma outra abordagem para o problema de otimização tratado é comparar a atual metodologia com o processo de decisão por estágios através da decomposição de Benders BENDERS (1962).

Referências Bibliográficas

- ANEEL, 2016. Disponível em: <<http://www.aneel.gov.br/>>.
- ARTZNER, P., DELBAEN, F., EBER, J.-M., et al., 1999, “Coherent measures of risk”, *Mathematical finance*, v. 9, n. 3, pp. 203–228.
- BENDERS, J. F., 1962, “Partitioning procedures for solving mixed-variables programming problems”, *Numerische mathematik*, v. 4, n. 1, pp. 238–252.
- CCEE, 2010, *Regras de Comercialização - Garantia Física*. Versão 1.0.
- CCEE, 2015, *Procedimentos de Comercialização Módulo 3 - Contratação de Energia e Potência Sumódulo 3.3 - Sazonalização e Revisão da Sazonalização de Garantia Física*. Revisão 2.0.
- DE CASTRO, N. J., BRANDÃO, R., ÁVILA, P., “O Equilíbrio Dinâmico e as Condições de Demanda e Oferta do Setor Elétrico Brasileiro”, .
- FALCETTA, F. A. M., *Evolução da capacidade de regularização do sistema hidrelétrico brasileiro*. Tese de Doutorado, Universidade de São Paulo.
- HULL, J. C., 2006, *Options, futures, and other derivatives*. Pearson Education India.
- JAPPE, G. A. T. C., OTHERS, 2014, “Um modelo para gestão de risco de geradores hidrelétricos sob despacho centralizado”, .
- JORION, P., 1997, *Value at risk*. McGraw-Hill, New York.
- KROKHMAL, P., PALMQUIST, J., URYASEV, S., 2002, “Portfolio optimization with conditional value-at-risk objective and constraints”, *Journal of risk*, v. 4, pp. 43–68.
- LIU, M., WU, F. F., NI, Y., 2006, “A survey on risk management in electricity markets”. In: *2006 IEEE Power Engineering Society General Meeting*, pp. 6–pp. IEEE.

- LONGERSTAEY, J., SPENCER, M., 1996, "RiskMetrics™ Technical Document", *Morgan Guaranty Trust Company of New York: New York*.
- MACEIRA, M., 2001, "Manual de Referência–Modelo Newave", *Relatório Técnico, CEPEL, Rio de Janeiro*.
- MARKOWITZ, H., 1952, "Portfolio selection", *The journal of finance*, v. 7, n. 1, pp. 77–91.
- ONS, 2016. Disponível em: <<http://www.ons.org.br>>.
- QUARANTA, A. G., ZAFFARONI, A., 2008, "Robust optimization of conditional value at risk and portfolio selection", *Journal of Banking & Finance*, v. 32, n. 10, pp. 2046–2056.
- ROCKAFELLAR, R. T., URYASEV, S., 2000, "Optimization of conditional value-at-risk", *Journal of risk*, v. 2, pp. 21–42.
- ROCKAFELLAR, R. T., URYASEV, S., 2002, "Conditional value-at-risk for general loss distributions", *Journal of banking & finance*, v. 26, n. 7, pp. 1443–1471.
- STREET, A., 2008, "Equivalente Certo e Medidas de Risco em decisões de Comercialização de Energia Elétrica", *Rio de Janeiro*.
- URYASEV, S., 2000, "Conditional value-at-risk: Optimization algorithms and applications". In: *Computational Intelligence for Financial Engineering, 2000.(CIFEr) Proceedings of the IEEE/IAFE/INFORMS 2000 Conference on*, pp. 49–57. IEEE.

Apêndice A

Códigos Implementados

- Otimização com Minimização do CVaR
- Mix dos Ativos nos Portfólios com otimização de CVaR e MV
- Adicionando a Fronteira Eficiente com restrição CVaR à Fronteira Eficiente de MV

```
\begin{verbatim}
%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
%-----Otimização com Minimização do CVaR e MV-----
% Autor: Mário Guerreiro
% Data: 15/11/2016
clear all;
close all;
clc;
[MatRets] = xlsread('Retornos','Plan1','A2:I8001');
```

Otimização com Minimização do CVaR

Escolha do objeto para a otimização com CVaR

```
pCVaR = PortfolioCVaR;
%Ativos
ativos = {'ativo1', 'ativo2', 'ativo3','ativo4'...
,'ativo5','ativo6','ativo7','ativo8','ativo9'};
pCVaR = pCVaR.setAssetList(ativos);
% Escolha do vetor de retornos dos ativos
pCVaR = setScenarios(pCVaR, MatRets);
% Intervalo de Confiança
```

```

beta = 0.95;
pCVaR.ProbabilityLevel = beta;
%Passo
passo=0.001;
% Restrições de soma dos pesos mínimo e máximo dos ativos no portfólio
pCVaR.LowerBudget = 1;
pCVaR.UpperBudget = 1;
% Limite mínimo de cada ativo no portfólio
LowerBound = [0.0;0.0;0.0;0.0;0.0;0.0;0.0;0.0;0.0];
% Limite máximo de cada ativo no portfólio
UpperBound = [0.25;0.3;0.35;0.4;0.25;0.3;0.35;0.4;0.2];
pCVaR.LowerBound = LowerBound;
pCVaR.UpperBound = UpperBound;

% Gráfico Cvar

% Pesos dos ativos nos limites de retorno mínimo e máximo do portfólio
WCVaR = estimateFrontierLimits(pCVaR);
WretminCVaR = WCVaR(:,1);
WretmaxCVaR = WCVaR(:,2);
%Retornos mínimo e máximo do portfólio
retminCVaR = mean(MatRets) * WretminCVaR;
retmaxCVaR = mean(MatRets) * WretmaxCVaR;
% Retorno alvo variando com passo definido entre o retmin e retmax
TargetReturnCVaR = retminCVaR:passo:retmaxCVaR;
% Peso dos ativos nos diferentes portfólios pertencentes a fronteira
% eficiente
[pwgtCVaR] = estimateFrontierByReturn(pCVaR,TargetReturnCVaR);
%plotFrontier(p);

%%Otimização por Média Variância

% Escolha do vetor de retornos dos ativos
Mean = mean(MatRets);
Covar = cov(MatRets);

```

```

% Escolha do objeto para a otimização com CVaR
pMV = Portfolio('assetmean',Mean,'assetcovar', Covar);

% Restrições de soma dos pesos mínimo e máximo dos ativos no portfólio
pMV.LowerBudget = 1;
pMV.UpperBudget = 1;

pMV.LowerBound = LowerBound;
pMV.UpperBound = UpperBound;
%Gráfico da fronteira eficiente
figure;
plotFrontier(pMV);
legend('Fronteira Eficiente Média Variância')
%
% Pesos dos ativos nos limites de retorno mínimo e máximo do portfólio
WMV = estimateFrontierLimits(pMV);
WretminMV = WMV(:,1);
WretmaxMV = WMV(:,2);
%Retornos mínimo e máximo do portfólio
retminMV = mean(MatRets) * WretminMV ;
retmaxMV = mean(MatRets) * WretmaxMV ;
% Retorno alvo variando com passo de 0.001 entre o retmin e retmax
%TargetReturnMV = retminMV:0.001:retmaxMV;
TargetReturnMV = retminCVaR:passo:retmaxCVaR;
% Peso dos ativos nos diferentes portfólios pertencentes a fronteira
% eficiente
[pwgtMV] = estimateFrontierByReturn(pMV,TargetReturnMV);
figure;
plotFrontier(pMV);

% VaR e CVaR do portfólio MV dado o Retorno Alvo
n = size(MatRets,1);
k =size(pwgtMV,2);
m =size(pwgtCVaR,2);

ReturnCVaR = MatRets * pwgtCVaR ;

```

```

VaRCVaR = zeros(1,size(ReturnCVaR,2));

CVaRCVaR = zeros(1,size(ReturnCVaR,2));
Psi_CVaR = zeros(1,size(ReturnCVaR,2));
Lambda_CVaR = zeros(1,size(ReturnCVaR,2));
CVaR_plus = zeros(1,size(ReturnCVaR,2));

for i=1 : m
VaRCVaR(1,i) = abs(quantile(ReturnCVaR(:,i), 1 - beta));
lowerTailCVaR(:,i) = ReturnCVaR(:,i) <= -VaRCVaR(1,i);
lowerTailCVaRplus(:,i) = ReturnCVaR(:,i) < -VaRCVaR(1,i);
aux = ReturnCVaR(:,i);
Psi_CVaR(1,i) = (size(lowerTailCVaR(:,i),1)...
- sum(lowerTailCVaR(:,i)))/size(lowerTailCVaR(:,i),1);

Lambda_CVaR(1,i) = abs((Psi_CVaR(1,i) - beta)/(1-beta));
CVaR_plus(1,i) = abs(mean(aux(lowerTailCVaRplus(:,i)))));
CVaRCVaR(1,i) = Lambda_CVaR(1,i) * VaRCVaR(1,i)...
+ (1-Lambda_CVaR(1,i)) * CVaR_plus(1,i);
end

ReturnMV = MatRets * pwgtMV ;
VaRMV = zeros(size(ReturnMV,2));

CVaRMV = zeros(1,size(ReturnMV,2));
Psi_MV = zeros(1,size(ReturnMV,2));
Lambda_MV = zeros(1,size(ReturnMV,2));
CVaRplus_MV = zeros(1,size(ReturnMV,2));
CVaR_MV = zeros(1,size(ReturnMV,2));

for i=1 : m
VaRMV(1,i) = abs(quantile(ReturnMV(:,i), 1 - beta));
lowerTailMV(:,i) = ReturnMV(:,i) <= -VaRMV(1,i);
lowerTailMVplus(:,i) = ReturnMV(:,i) < -VaRMV(1,i);
aux = ReturnMV(:,i);

```

```

Psi_MV(1,i) = (size(lowerTailMV(:,i),1)...
- sum(lowerTailMV(:,i))/size(lowerTailMV(:,i),1);
Lambda_MV(1,i) = abs((Psi_MV(1,i) - beta)/(1-beta));
CVaRplus_MV(1,i) = abs(mean(aux(lowerTailMVplus(:,i))));
CVaR_MV(1,i) = Lambda_MV(1,i) * VaRMV(1,i)...
+ (1-Lambda_MV(1,i)) * CVaRplus_MV(1,i);
end

CVaR2 = estimatePortRisk(pCVaR,pwgtMV);
% Gráfico da fronteira eficiente
figure;
plotFrontier(pCVaR);
figure;
plotFrontier(pCVaR);
hold on
%plot(CVaRCVaR,TargetReturnCVaR);
plot(CVaR_MV,TargetReturnCVaR);
legend('Fronteira Eficiente CVaR')
%plot(CVaR2,TargetReturnCVaR);
legend('Fronteira Eficiente CVaR','Fronteira Eficiente MV')

hold off
%

figure(2)
histfit(MatRets * WretminCVaR)

```

Mix dos Ativos nos Portfólios com otimização de CVaR e MV

```

figure;
subplot(1,2,1);
area(pwgtCVaR');
title('Pesos dos Portfólios CVaR')
ylim([0 1])

subplot(1,2,2);

```

```

area(pwgtMV');
title('Pesos dos Portfólios MV')
ylim([0 1])
legend(pCVaR.AssestList)

```

Adicionando a Fronteira Eficiente com restrição CVaR à Fronteira Eficiente de MV

calculando o desvio padrão para o portfólio com restrição CVaR

```

pCVaRStd = pCVaR.estimatePortStd(pwgtCVaR);

%Gráfico com as duas fronteiras eficientes:
figure;
plotFrontier(pMV)
hold on
plot(pCVaRStd, TargetReturnCVaR, '-r','LineWidth',2);
legend('Fronteira Eficiente de Média Variância',...
'Fronteira Eficiente CVaR',...
'Location','SouthEast')
%xlim([min(retminCVaR,retminMV) min(retmaxCVaR,retmaxMV)]);

%%Teste de Normalidade das Carteiras Geradas

J90 = zeros(1,size(MatRets,2));
J95 = zeros(1,size(MatRets,2));
J99 = zeros(1,size(MatRets,2));

% Teste Jarque-Bera:
for i = 1:size(MatRets,2)
J90(1,i) = jbstest(MatRets(:,i),0.10);
J95(1,i) = jbstest(MatRets(:,i),0.05);
J99(1,i) = jbstest(MatRets(:,i),0.01);
end

% Total de Ativos que rejeitam a hipótese nula de que a distribuição é
% normal em percentual

```

```
ativosnaonormais90 = sum(J90)/size(J90,2);  
ativosnaonormais95 = sum(J95)/size(J90,2);  
ativosnaonormais99 = sum(J99)/size(J90,2);
```